

Détection des faux billets avec Python



SOMMAIRE

- Contexte et objectifs
- Les données
- Analyse exploratoire
- Traitements de données
- Modélisation
- Résultat
- Application
- Conclusion



INTRODUCTION

Contexte

- Lutte contre la contrefaçon de billets en euros
- Besoin d'automatiser la détection

Objectif

- Créer une application ML capable de distinguer un vrai billet d'un faux billet

Enjeux Business

- Protéger l'économie européenne

LES DONNÉES

1 fichier CSV qui contient:

1500 billets scannés:

- 1000 vrais billets
- 500 faux billets


6 variables géométriques

- diagonal
- height_left
- height_right
- margin_low
- margin_up
- length

1 variable cible


- is_genuine (Vrai = 1 / Faux = 0)

ANALYSE EXPLORATOIRE



- Dataset équilibré : 67% vrais / 33% faux
- Variables continues mesurées en millimètres
- Distributions différentes entre vrais et faux billets sur certaines variables
- Valeurs manquantes détectées sur `margin_low`

ANALYSE EXPLORATOIRE



- Les vrais billets ont une longueur plus grande
- Les faux billets ont une marge basse plus grande
- La diagonale est similaire pour les deux types de billets

TRAITEMENTS DE DONNÉES

Constat

- 37 Valeurs manquantes sur margin_low uniquement
- Pourcentage: 2,47%
- is genuine: 29 true / 8 false

Solution choisie

- Régression Linéaire pour imputer les valeurs manquantes

Pourquoi ce choix


- Méthode plus précise que la moyenne
- Utilise les relations entre variables
- Préserve la structure des données

MATRICE DE CORRELATION AVANT IMPUTATION



- Rouge foncée forte corrélation positive (+1)
- Bleu forte corrélation négative (-1)
- Blanc/Beige pas de corrélation (0)
- length vs is_genuine = +0.85 → Corrélation FORTE
- margin_low vs is_genuine = -0.78 → Corrélation FORTE
- diagonal vs is_genuine = +0.13 → Corrélation FAIBLE

MATRICE DE CORRELATION APRES IMPUTATION



- Corrélations identiques avant et après imputation
- Imputation validée
- Données fiables pour la modélisation

VARIABLES CLÉS RETENUES

Variable	Corrélation	Interprétation
<u>Length</u>	+0.85	Très forte
<u>Margin_low</u>	-0.78	Très forte
<u>Margin_up</u>	-0.61	Forte
<u>Height_right</u>	-0.49	Modérée
<u>Height_left</u>	-0.38	Faible
Diagonal	+0.13	Très faible

Toutes les variables sont conservées pour la modélisation

MÉTHODOLOGIES MACHINE LEARNING

Séparation Train/test

- 80% Train (1200 billets)
- 20% Test (300 billets)

Normalisation

- StandardScaler
- Même échelle pour tous les algorithmes
- Évite les biais de calcul


4 algorithmes testés

- K-Means (Non supervisé)
- Régression Logistique
- KNN
- Random Forest

Métriques d'évaluation

- Accuracy
- Precision
- Recall
- F1-Score
- AUC-ROC

MATRICE DE CONFUSION K-MEANS



Principe: Regroupe les billets en 2 clusters sans connaître les labels au préalable

Résultat:

- Accuracy : 98.67%
- AUC-ROC : 99.92%
- Faux billets manqués : 2


Points forts:

- Fonctionne sans labels

Limite:

- Légèrement moins précis que les modèles supervisés

MATRICE DE CONFUSION REGRESSION LOGISTIQUE



Principe: Calcule la probabilité qu'un billet soit vrai ou faux


Résultat:

- Accuracy : 99%
- AUC-ROC : 99.95%
- Faux billets manqués : 2

Points forts:

- Fournit des probabilités de confiance
- Simple et interprétable

MATRICE DE CONFUSION K-NEAREST NEIGHBORS



Principe: Compare chaque billet à ses K voisins les plus proches

Résultat:

- Accuracy : 99%
- AUC-ROC : 99.94%
- Faux billets manqués : 2


Points forts:

- Fournit des probabilités de confiance
- Simple et interprétable

Limite :

- Moins rapide sur de grands dataset

MATRICE DE CONFUSION RANDOM FOREST



Principe: Combine plusieurs arbres de décision pour plus de précision

Résultat:

- Accuracy : 99%
- AUC-ROC : 99.92%
- Faux billets manqués : 2

Limite:

- Moins interprétable et plus complexe

TABLEAU COMPARATIF

Modèle	Accuracy	Precision	Recall global	Recall faux	F1-Score	FN (billets Manqués)	Auc-Roc
K-means	98.67%	99%	99%	98%	99%	2	99.92%
Régression logistique	99%	99%	99.5%	98%	99.25%	2	99.95%
KNN	99%	99%	99.5%	98%	99.25%	2	99.94%
Random forest	99%	99%	99.5%	98%	99.25%	2	99.92%

Objectif : Recall Faux = 1.0000 (0 faux billet manqué)

Meilleur modèle : Régression Logistique car:

- Meilleur AUC-ROC : 99.95%
- Simple, rapide et interprétable
- Fournit des probabilités de confiance

APPLICATION

Étape 1

- Scanner le billet et saisir les 6 mesures géométriques

Étape 2

- L'application analyse les données avec le modèle

Étape 3

- Résultat immédiat : VRAI BILLET ou FAUX BILLET
Probabilité de confiance affichée

CONCLUSION

Ce qu'on a accompli

- Une application capable de détecter automatiquement les faux billets
- En quelques secondes seulement
- Avec une très haute fiabilité

Impact Business

AVANT :

- Détection manuelle
- Longue et coûteuse
- Risque d'erreur humaine

APRÈS :

- Détection automatique
- Rapide et fiable
- Réduction des coûts
- Moins d'erreurs

Perspectives

- Enrichir le dataset pour viser 100% de Recall
- Déploiement sur le terrain
- Mise à jour régulière du modèle